



Regresión Lineal

Matemática 4


Facultad de Informática - UNLP - 2025



Regresión Lineal

Definición: La regresión lineal es una técnica de modelado estadístico que se emplea para describir una variable de respuesta continua como una función de una o varias variables predictoras. Puede ayudar a comprender y predecir el comportamiento de sistemas complejos o a analizar datos experimentales, Informáticos, financieros y biológicos.


- **Regresión Lineal Simple**
- **Regresión Lineal Múltiple**



Regresión Lineal Simple



Gráfico de dispersión



Regresión Lineal Simple



Modelo de Regresión Lineal Simple:

$$Y = \beta_1 X + \beta_0 + \varepsilon$$

Lineal en los parámetros β_1 , β_0 y simple porque involucra solo una variable predictora.

Y: Variable Respuesta o Dependiente

X: Variable Predictora o Independiente

ε : Error aleatorio

β_1 : Pendiente

β_0 : Ordenada

Suposiciones del Modelo:

- ε es Independiente
- $\varepsilon \sim N(0, \sigma^2)$

Regresión Lineal Simple




En general podemos decir que al fijar el valor de x observamos el valor de la variable Y . Si bien x es fijo, el valor de Y está afectado por el **error aleatorio** ε . Por lo tanto, ε **determina las propiedades de** Y .

$$E(Y) = E(\beta_1 x + \beta_0 + \varepsilon) = E(\beta_1 x) + E(\beta_0) + E(\varepsilon) = \beta_1 x + \beta_0$$

$$V(Y) = V(\beta_1 x + \beta_0 + \varepsilon) = V(\beta_1 x) + V(\beta_0) + V(\varepsilon) = V(\varepsilon) = \sigma^2$$

En consecuencia, el modelo de regresión verdadero $E(Y) = \beta_1 x + \beta_0$ es una recta de valores promedio.

Regresión Lineal Simple



Objetivo: Encontrar la recta que mejor se ajuste a los datos observados.

Regresión Lineal Simple



Método de Mínimos Cuadrados: La recta que mejor se ajuste a los datos observados será aquella cuyos valores de β_1 y β_0 minimicen la siguiente expresión:

$$f(\beta_1, \beta_0) = \sum_{i=1}^n \varepsilon_i^2 = \sum_{i=1}^n (y_i - \beta_1 x_i - \beta_0)^2$$

A dichos valores lo denotaremos como $\hat{\beta}_1$, $\hat{\beta}_0$ y los llamaremos estimadores de mínimos cuadrados de la pendiente y la ordenada.

Regresión Lineal Simple



$$f(\beta_0, \beta_1) = \sum_{i=1}^n (y_i - \beta_1 x_i - \beta_0)^2$$

$$\frac{\partial f(\beta_0, \beta_1)}{\partial \beta_0} = \sum_{i=1}^n 2 \cdot (y_i - \beta_1 x_i - \beta_0) \cdot (-1) = \sum_{i=1}^n 2 \cdot (-y_i + \beta_1 x_i + \beta_0) = 0$$

$$\frac{\partial f(\beta_0, \beta_1)}{\partial \beta_1} = \sum_{i=1}^n 2 \cdot (y_i - \beta_1 x_i - \beta_0) \cdot (-x_i) = \sum_{i=1}^n 2 \cdot (-y_i x_i + \beta_1 x_i^2 + \beta_0 x_i) = 0$$

Regresión Lineal Simple



$$\sum_{i=1}^n -y_i + \sum_{i=1}^n \beta_1 x_i + \sum_{i=1}^n \beta_0 = -\sum_{i=1}^n y_i + \beta_1 \sum_{i=1}^n x_i + \beta_0 n = 0$$

$$\sum_{i=1}^n -x_i y_i + \sum_{i=1}^n \beta_1 x_i^2 + \sum_{i=1}^n \beta_0 x_i = -\sum_{i=1}^n x_i y_i + \beta_1 \sum_{i=1}^n x_i^2 + \beta_0 \sum_{i=1}^n x_i = 0$$

Regresión Lineal Simple



Reordenando:

$$\beta_1 \sum_{i=1}^n x_i + n\beta_0 = \sum_{i=1}^n y_i$$

$$\beta_1 \sum_{i=1}^n x_i^2 + \beta_0 \sum_{i=1}^n x_i = \sum_{i=1}^n x_i y_i$$

Ecuaciones Normales

Regresión Lineal Simple



Resolvamos el sistema de ecuaciones:

$$\beta_1 \sum_{i=1}^n x_i + n\beta_0 = \sum_{i=1}^n y_i \rightarrow \beta_0 = \frac{\sum y_i}{n} - \beta_1 \frac{\sum x_i}{n} = \bar{y} - \beta_1 \bar{x}$$

Reemplazando en la segunda ecuación:

$$\beta_1 \sum_{i=1}^n x_i^2 + (\bar{y} - \beta_1 \bar{x}) \sum_{i=1}^n x_i = \sum_{i=1}^n x_i y_i$$

Regresión Lineal Simple



$$\beta_1 \sum_{i=1}^n x_i^2 + \bar{y} \sum_{i=1}^n x_i - \beta_1 \bar{x} \sum_{i=1}^n x_i = \sum_{i=1}^n x_i y_i$$

$$\beta_1 \sum_{i=1}^n x_i^2 - \beta_1 \bar{x} \sum_{i=1}^n x_i = \sum_{i=1}^n x_i y_i - \bar{y} \sum_{i=1}^n x_i$$

$$\beta_1 \left(\sum_{i=1}^n x_i^2 - \bar{x} \sum_{i=1}^n x_i \right) = \sum_{i=1}^n x_i y_i - \bar{y} \sum_{i=1}^n x_i$$

$$\beta_1 = \frac{\sum x_i y_i - \bar{y} \sum x_i}{\left(\sum x_i^2 - \bar{x} \sum x_i \right)} = \frac{\sum x_i y_i - \frac{(\sum x_i)(\sum y_i)}{n}}{\sum x_i^2 - \frac{(\sum x_i)^2}{n}}$$



Regresión Lineal Simple



Los estimadores de mínimos cuadrados la pendiente y la ordenada serán:

$$\hat{\beta}_1 = \frac{\sum x_i y_i - \frac{(\sum x_i)(\sum y_i)}{n}}{\sum x_i^2 - \frac{(\sum x_i)^2}{n}} \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

Y la recta de regresión estimada es:

$$\hat{y}_i = \hat{\beta}_1 x_i + \hat{\beta}_0$$

Regresión Lineal Simple



Otra forma de expresar el estimador de la pendiente es:

$$\hat{\beta}_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} \quad \hat{\beta}_1 = \frac{\sum y_i(x_i - \bar{x})}{\sum (x_i - \bar{x})^2} \quad \hat{\beta}_1 = \frac{S_{xy}}{S_{xx}}$$

Donde:

$$S_{xy} = \sum (x_i - \bar{x})(y_i - \bar{y}) = \sum y_i(x_i - \bar{x}) = \sum x_i y_i - \frac{(\sum x_i)(\sum y_i)}{n}$$

$$S_{xx} = \sum (x_i - \bar{x})^2 = \sum x_i^2 - \frac{(\sum x_i)^2}{n} \rightarrow \text{desviación } (x_i) \text{ de su media}$$

Regresión Lineal Simple



Demostración S_{xy} :

$$\sum (x_i - \bar{x})(y_i - \bar{y})$$

$$\sum (x_i y_i - x_i \bar{y} - \bar{x} y_i + \bar{y} \bar{x})$$

$$\sum x_i y_i - \sum x_i \bar{y} - \sum \bar{x} y_i + \sum \bar{y} \bar{x}$$

$$\sum x_i y_i - \bar{y} \sum x_i - \bar{x} \sum y_i + n \bar{y} \bar{x}$$

$$\sum x_i y_i - \bar{y} \sum x_i - \bar{x} \sum y_i + n \bar{y} \bar{x}$$

$$\sum x_i y_i - \bar{y} \frac{\sum x_i}{n} - \bar{x} \frac{\sum y_i}{n} + n \bar{y} \bar{x}$$

$$\sum x_i y_i - n \bar{x} \bar{y} - n \bar{x} \bar{y} + n \bar{x} \bar{y}$$

$$\sum x_i y_i - n \bar{x} \bar{y}$$

$$\sum x_i y_i - \frac{(\sum x_i)(\sum y_i)}{n}$$

Regresión Lineal Simple



Demostración S_{xx} :

$$\sum (x_i - \bar{x})^2$$

$$\sum (x_i^2 - 2x_i\bar{x} + \bar{x}^2)$$

$$\sum x_i^2 - 2\bar{x} \sum x_i + n\bar{x}^2$$

$$\sum x_i^2 - 2\bar{x} \frac{\sum x_i}{n} + n\bar{x}^2$$

$$\sum x_i^2 - 2n\bar{x}^2 + n\bar{x}^2$$

$$\sum x_i^2 - n\bar{x}^2$$

$$\sum x_i^2 - n \frac{(\sum x_i)^2}{n^2}$$

$$\sum x_i^2 - \frac{(\sum x_i)^2}{n}$$

Regresión Lineal Simple



Nota 1: La recta de regresión estimada:

$$\hat{y}_i = \hat{\beta}_1 x_i + \hat{\beta}_0$$

No debe ser utilizada para pronosticar valores de la variable independiente que no se encuentren dentro del rango de la misma. Porque se corre el **peligro de extrapolación**.



Regresión Lineal Simple



Nota 2: Si la variable independiente pasa a tener la siguiente expresión:

$$ax + c$$

con a y c constantes cualesquiera. Entonces la nueva recta de regresión estimada para $E(Y) = \beta_1 x + \beta_0$ es:

$$\hat{y}' = \hat{\beta}_1(ax + c) + \hat{\beta}_0$$

$$\hat{y}' = \hat{\beta}_1 ax + \hat{\beta}_1 c + \hat{\beta}_0$$

$$\hat{y}' = (\hat{\beta}_1 a)x + (\hat{\beta}_1 c + \hat{\beta}_0)$$

Denotando $\hat{\beta}'_1 = \hat{\beta}_1 a$ y $\hat{\beta}'_0 = \hat{\beta}_1 c + \hat{\beta}_0$ nos queda:

$$\hat{y}' = \hat{\beta}'_1 x + \hat{\beta}'_0$$

Regresión Lineal Simple



Propiedades de los estimadores de mínimos cuadrados:

Como $\hat{\beta}_1$ y $\hat{\beta}_0$ son estimadores de β_1 y β_0 respectivamente, son variables aleatorias, por lo tanto, podemos calcular su esperanza y varianza. Como estamos asumiendo que x no es v.a. entonces $\hat{\beta}_1$ y $\hat{\beta}_0$ son funciones de la variable aleatoria Y .

$$E(\hat{\beta}_1) = \beta_1 \quad V(\hat{\beta}_1) = \frac{\sigma^2}{S_{xx}}$$

$$E(\hat{\beta}_0) = \beta_0 \quad V(\hat{\beta}_0) = \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right)$$

$\hat{\beta}_1$ y $\hat{\beta}_0$ son estimadores insesgado de β_1 y β_0



Regresión Lineal Simple



Estimación de la varianza σ^2

El parámetro σ^2 determina la cantidad de variabilidad en el modelo de regresión.

- Un valor grande de σ^2 conducirá a (x_i, y_i) observados que están bastante dispersos entorno a la recta de regresión verdadera.
- Mientras que σ^2 sea pequeña los puntos observados tenderán a quedar cerca de la recta de regresión verdadera.



Regresión Lineal Simple



Para estimar la varianza vamos a usar las desviaciones verticales entre los valores observados y valores estimados. Las cuales nombraremos **Residuos**:

$$e_i = y_i - \hat{y}_i = y_i - \hat{\beta}_1 x_i - \hat{\beta}_0$$

Y a la suma al cuadrado de la misma llamaremos **Suma de los Residuos al Cuadrado** y lo denotamos como SS_R :

$$SS_R = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n (y_i - \hat{\beta}_1 x_i - \hat{\beta}_0)^2$$

Regresión Lineal Simple



Entonces el estimador insesgado de σ^2 es:

$$\hat{\sigma}^2 = \frac{SS_R}{n - 2}$$

Otra forma de expresar la suma de los residuos al cuadrado es:


$$SS_R = S_{yy} - \frac{(S_{xy})^2}{S_{xx}} = S_{yy} - \hat{\beta}_1 S_{xy}$$

$$S_{yy} = \sum (y_i - \bar{y})^2 = \sum y_i^2 - \frac{(\sum y_i)^2}{n} \rightarrow \text{desviación } (y_i) \text{ de su media}$$

Regresión Lineal Simple



Coeficiente de determinación



$(y_i - \hat{y}_i)$: Desviación no explicada del valor observado, de su media.

$(\hat{y}_i - \bar{y})$: Desviación explicada del valor observado, de su media.

$(y_i - \bar{y})$: Desviación total del valor observado, de su media.

Regresión Lineal Simple



Si generalizamos lo anterior para n observaciones y sumando tenemos :

$$\sum (y_i - \bar{y})^2 = \sum (\hat{y}_i - \bar{y})^2 + \sum (y_i - \hat{y}_i)^2$$

Reordenando:

$$\sum (\hat{y}_i - \bar{y})^2 = \sum (y_i - \bar{y})^2 - \sum (y_i - \hat{y}_i)^2$$

Regresión Lineal Simple



Dividiendo ambos miembros por la desviación total de los valores observados:

$$\underbrace{\frac{\sum(\hat{y}_i - \bar{y})^2}{\sum(y_i - \bar{y})^2}}_{\text{Proporción Explicada}} = 1 - \underbrace{\frac{\sum(y_i - \hat{y}_i)^2}{\sum(y_i - \bar{y})^2}}_{\text{Proporción No Explicada}}$$

El coeficiente de determinación, denotado por R^2 , está dado por:

$$R^2 = 1 - \frac{SS_R}{S_{yy}}$$

Se interpreta como la proporción de variación de y observada que puede ser explicada por el modelo de regresión lineal simple.


Regresión Lineal Simple




El coeficiente toma los siguientes valores:

$$0 \leq R^2 \leq 1$$


Mientras más próximo a la unidad el valor de R^2 , mejor será nuestro modelo de regresión lineal simple al explicar la variación de y .



$$R^2 = 0,2$$



$$R^2 = 0,8$$




$$R^2 = 1$$

Regresión Lineal Simple



Covarianza



$$\text{I)} \quad \left. \begin{array}{l} (x_i - \bar{x}) < 0 \\ (y_i - \bar{y}) < 0 \end{array} \right\} \rightarrow (x_i - \bar{x})(y_i - \bar{y}) > 0$$

$$\text{III)} \quad \left. \begin{array}{l} (x_i - \bar{x}) > 0 \\ (y_i - \bar{y}) > 0 \end{array} \right\} \rightarrow (x_i - \bar{x})(y_i - \bar{y}) > 0$$

$$\text{II)} \quad \left. \begin{array}{l} (x_i - \bar{x}) > 0 \\ (y_i - \bar{y}) < 0 \end{array} \right\} \rightarrow (x_i - \bar{x})(y_i - \bar{y}) < 0$$

$$\text{IV)} \quad \left. \begin{array}{l} (x_i - \bar{x}) < 0 \\ (y_i - \bar{y}) > 0 \end{array} \right\} \rightarrow (x_i - \bar{x})(y_i - \bar{y}) < 0$$

Regresión Lineal Simple



Entonces queremos una medida que sea positiva, si es que los datos se concentran en torno a la recta naranja y negativa si es que los datos se concentran entorno a la recta azul. Dicha medida se define como:

$$\text{Cov}(x, y) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

La covarianza en general no es una función acotada, es decir no tiene un máximo y por lo tanto es difícil comparar relativamente para diferentes pares de variables.

Regresión Lineal Simple

Coeficiente de Correlación Lineal



$$\left| \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) \right| \leq \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \cdot \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2}$$

$$\frac{1}{n} \left| \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) \right| \leq \frac{1}{n} \sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \cdot \sum_{i=1}^n (y_i - \bar{y})^2}$$

$$|S_{xy}| \leq \sqrt{S_{xx} \cdot S_{yy}}$$

$$\frac{|S_{xy}|}{\sqrt{S_{xx} \cdot S_{yy}}} \leq 1$$

$$|r| \leq 1$$

CORRELACIÓN NO IMPLICA CAUSALIDAD
CORRELACIÓN NO IMPLICA CAUSALIDAD
CORRELACIÓN NO IMPLICA CAUSALIDAD
CORRELACIÓN NO IMPLICA CAUSALIDAD



Regresión Lineal Simple



Coeficiente de Correlación Lineal: El coeficiente de correlación es la medida para describir qué tan fuerte es la relación lineal entre dos variables.

$$r = \frac{S_{xy}}{\sqrt{S_{xx}S_{yy}}}$$

Otra forma de expresar el coeficiente de correlación lineal es:


$$r = \sqrt{R^2}$$

Regresión Lineal Simple



Propiedades del coeficiente de correlación lineal:

- 1) $-1 \leq r \leq 1$
- 2) $r = 0 \rightarrow X$ e Y no están correlacionadas
- 3) $r = 1 \rightarrow$ Correlación directa perfecta
- 4) $r = -1 \rightarrow$ Correlación inversa perfecta
- 5) r Solo mide la correlación lineal entre X e Y



Regresión Lineal Simple



Ejemplo 1


En la tabla siguiente, se muestran la variable y , rendimiento de un sistema informático, respecto a la variable x , numero de buffer:

x	5	10	15	20	25	5	10	15	20	25	5	10	15	20	25
y	9.6	20.1	29.9	39.1	50.0	9.6	19.4	29.7	40.3	49.9	10.7	21.3	30.7	41.8	51.2

A partir de la tabla anterior, se quiere ajustar la variable y como función de x .

- Estimar la recta de regresión
- Estimar $\hat{\sigma}^2$
- Calcular la bondad del ajuste y el coeficiente de correlación lineal

Regresión Lineal Simple



Regresión Lineal Simple



n	x_i	y_i	x_i^2	y_i^2	$x_i y_i$
1	5	9,6	25	92,16	48
2	10	20,1	100	404,01	201
3	15	29,9	225	894,01	448,5
4	20	39,1	400	1528,81	782
5	25	50	625	2500	1250
6	5	9,6	25	92,16	48
7	10	19,4	100	376,36	194
8	15	29,7	225	882,09	445,5
9	20	40,3	400	1624,09	806
10	25	49,9	625	2490,01	1247,5
11	5	10,7	25	114,49	53,5
12	10	21,3	100	453,69	213
13	15	30,7	225	942,49	460,5
14	20	41,8	400	1747,24	836
15	25	51,2	625	2621,44	1280
Σ	225	453,3	4125	16763,05	8313,5

Resumen de estadísticos

$$\bar{x} = \frac{\sum x_i}{n} = \frac{225}{15} = 15$$

$$\bar{y} = \frac{\sum y_i}{n} = \frac{453,3}{15} = 30,22$$

$$S_{xx} = \sum x_i^2 - \frac{(\sum x_i)^2}{n} = 4125 - \frac{(225)^2}{15} = 750$$

$$S_{xy} = \sum x_i y_i - \frac{\sum x_i \sum y_i}{n} = 8313,5 - \frac{(225)(453,3)}{15} = 1514$$

$$S_{yy} = \sum y_i^2 - \frac{(\sum y_i)^2}{n} = 16763,05 - \frac{(453,3)^2}{15} = 3064,324$$

Regresión Lineal Simple



$$\mathbf{a) \hat{y} = \hat{\beta}_1 x + \hat{\beta}_0}$$

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}} = \frac{1415}{750} = 2,0187$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \cdot \bar{x} = 30,22 - 2,0187 \cdot 15 = -0,06$$

$$\hat{y} = 2,0187x - 0,06$$

Regresión Lineal Simple



$$\mathbf{b)} \hat{\sigma}^2 = \frac{SS_R}{n-2}$$

$$SS_R = S_{yy} - \frac{S_{xy}^2}{S_{xx}} = 3064,324 - \frac{(1415)^2}{750} = 8,062$$

$$\hat{\sigma}^2 = \frac{8,062}{15 - 2} = 0,62$$

$$\mathbf{c)} R^2 = 1 - \frac{SS_R}{S_{yy}}$$

$$R^2 = 1 - \frac{8,062}{3064,324} = 0,997$$

$$r = \sqrt{R^2}$$

$$r = \sqrt{0,99} = 0,998$$

Inferencias sobre los parámetros de Regresión



Repaso

Intervalos de confianza simétricos

$$IC(\theta) = (\hat{\theta} - \varepsilon ; \hat{\theta} + \varepsilon)$$

$$L = L_2 - L_1 \quad L_1 = \hat{\theta} - \varepsilon \quad L_2 = \hat{\theta} + \varepsilon$$

$$\hat{\theta} = \frac{L_2 + L_1}{2} \quad \varepsilon = \frac{L}{2}$$



Inferencias sobre los parámetros de Regresión

Inferencias sobre β_1

Para poder hacer inferencia sobre β_1 necesitamos conocer lo siguiente sobre el estimador $\hat{\beta}_1$

$$E(\hat{\beta}_1) = \beta_1 \quad V(\hat{\beta}_1) = \frac{\sigma^2}{S_{xx}} \quad S_{\hat{\beta}_1} = \sqrt{\frac{\hat{\sigma}^2}{S_{xx}}} \quad \hat{\beta}_1 \sim N\left(\beta_1, \frac{\sigma^2}{S_{xx}}\right)$$

Teorema: La suposición del modelo de regresión lineal simple implica la variable estándar:

$$T = \frac{\hat{\beta}_1 - \beta_1}{\sqrt{\frac{\hat{\sigma}^2}{S_{xx}}}} \sim t_{n-2}$$

Inferencias sobre los parámetros de Regresión

Intervalo de confianza para β_1

$$P\left(-t_{\frac{\alpha}{2}, n-2} \leq T \leq t_{\frac{\alpha}{2}, n-2}\right) = 1 - \alpha$$

$$\left(-t_{\frac{\alpha}{2}, n-2} \leq \frac{\hat{\beta}_1 - \beta_1}{\sqrt{\frac{\hat{\sigma}^2}{S_{xx}}}} \leq t_{\frac{\alpha}{2}, n-2}\right)$$

Despejando β_1 obtenemos un intervalo de nivel de confianza $1 - \alpha$ para β_1

$$\left(\hat{\beta}_1 - t_{\frac{\alpha}{2}, n-2} \sqrt{\hat{\sigma}^2 / S_{xx}} ; \hat{\beta}_1 + t_{\frac{\alpha}{2}, n-2} \sqrt{\hat{\sigma}^2 / S_{xx}}\right)$$

Inferencias sobre los parámetros de Regresión

Test de Hipótesis sobre β_1

$$H_0: \beta_1 \begin{cases} = \beta_{10} \\ = \beta_{10} \\ = \beta_{10} \end{cases}$$

VS

$$H_1: \beta_1 \begin{cases} > \beta_{10} \\ \neq \beta_{10} \\ < \beta_{10} \end{cases}$$

Estadístico de prueba:

$$T = \frac{\hat{\beta}_1 - \beta_{10}}{\sqrt{\frac{\hat{\sigma}^2}{S_{xx}}}} \sim t_{n-2} \text{ bajo } H_0$$

Regla de decisión:

Si $H_1: \beta_1 \neq \beta_{10}$ se rechaza H_0 si $|T| > t_{\frac{\alpha}{2}, n-2}$

Si $H_1: \beta_1 > \beta_{10}$ se rechaza H_0 si $T > t_{\alpha, n-2}$

Si $H_1: \beta_1 < \beta_{10}$ se rechaza H_0 si $T < -t_{\alpha, n-2}$

Inferencias sobre los parámetros de Regresión

Test de Hipótesis sobre β_1

Un caso especial importante es cuando $H_0: \beta_1 = 0$ vs $H_1: \beta_1 \neq 0$

Estas hipótesis están relacionadas con la **significancia de la regresión**.

- Aceptar $H_0: \beta_1 = 0$ es equivalente a concluir que no hay ninguna relación lineal entre x e Y .
- Si $H_0: \beta_1 = 0$ se rechaza implica que x tiene importancia al explicar la variabilidad en Y .

También puede significar que el modelo lineal es adecuado, o que, aunque existe efecto lineal pueden obtenerse mejores resultados agregando términos polinomiales de mayor grado en x .

Inferencias sobre los parámetros de Regresión

Inferencias sobre β_0

Para poder hacer inferencia sobre β_0 necesitamos conocer lo siguiente sobre el estimador $\hat{\beta}_0$

$$E(\hat{\beta}_0) = \beta_0 \quad V(\hat{\beta}_0) = \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right) \quad S_{\hat{\beta}_0} = \sqrt{\hat{\sigma}^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right)} \quad \hat{\beta}_0 \sim N \left(\beta_0, \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right) \right)$$

Teorema: La suposición del modelo de regresión lineal simple implica la variable estándar:

$$T = \frac{\hat{\beta}_0 - \beta_0}{\sqrt{\hat{\sigma}^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right)}} \sim t_{n-2}$$

Inferencias sobre los parámetros de Regresión

Intervalo de confianza para β_0

$$P\left(-t_{\frac{\alpha}{2}, n-2} \leq T \leq t_{\frac{\alpha}{2}, n-2}\right) = 1 - \alpha$$

$$\left(-t_{\frac{\alpha}{2}, n-2} \leq \frac{\hat{\beta}_0 - \beta_0}{\sqrt{\hat{\sigma}^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}\right)}} \leq t_{\frac{\alpha}{2}, n-2}\right)$$

Despejando β_0 obtenemos un intervalo de nivel de confianza $1 - \alpha$ para β_0

$$\left(\hat{\beta}_0 - t_{\frac{\alpha}{2}, n-2} \sqrt{\hat{\sigma}^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}\right)}; \hat{\beta}_0 + t_{\frac{\alpha}{2}, n-2} \sqrt{\hat{\sigma}^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}\right)}\right)$$

Inferencias sobre los parámetros de Regresión

Test de Hipótesis sobre β_0

$$H_0: \beta_0 \begin{cases} = \beta_{00} \\ = \beta_{00} \\ = \beta_{00} \end{cases} \quad \text{VS} \quad H_1: \beta_0 \begin{cases} > \beta_{00} \\ \neq \beta_{00} \\ < \beta_{00} \end{cases}$$

Estadístico de prueba:

$$T = \frac{\hat{\beta}_0 - \beta_{00}}{\sqrt{\hat{\sigma}^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right)}} \sim t_{n-2} \text{ bajo } H_0$$

Regla de decisión:

Si $H_1: \beta_0 \neq \beta_{00}$ se rechaza H_0 si $|T| > t_{\frac{\alpha}{2}, n-2}$

Si $H_1: \beta_0 > \beta_{00}$ se rechaza H_0 si $T > t_{\alpha, n-2}$

Si $H_1: \beta_0 < \beta_{00}$ se rechaza H_0 si $T < -t_{\alpha, n-2}$

Inferencias sobre los parámetros de Regresión

Intervalo de confianza para la respuesta media

Buscamos un intervalo de confianza para estimar $\beta_0 + \beta_1 x^*$, es decir estimar la media $E(Y)$ para un valor específico x^*

Sea $\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 x^*$, donde x^* es algún valor fijo de x . Entonces:

$$E(\hat{Y}) = E(\hat{\beta}_0 + \hat{\beta}_1 x^*) = \beta_0 + \beta_1 x^*$$

$$V(\hat{Y}) = V(\hat{\beta}_0 + \hat{\beta}_1 x^*) = \sigma^2 \left(\frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{xx}} \right)$$

$$S_{\hat{Y}} = \hat{\sigma}^2 \left(\frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{xx}} \right)$$

$\hat{Y}$ tiene distribución normal con esperanza y varianza anteriores

Inferencias sobre los parámetros de Regresión

Intervalo de confianza para la respuesta media

Teorema: La variable

$$T = \frac{\hat{\beta}_0 + \hat{\beta}_1 x^* - (\beta_0 + \beta_1 x^*)}{\sqrt{\hat{\sigma}^2 \left(\frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{xx}} \right)}}$$

tiene distribución student con $n - 2$ grados de libertad

Inferencias sobre los parámetros de Regresión

Intervalo de confianza para la respuesta media

Un **intervalo de confianza** de $(1 - \alpha)$ para $\beta_0 + \beta_1 x^*$ de la línea de regresión verdadera es

$$\left(\hat{\beta}_0 + \hat{\beta}_1 x^* - t_{\frac{\alpha}{2}, n-2} \sqrt{\hat{\sigma}^2 \left(\frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{xx}} \right)}; \hat{\beta}_0 + \hat{\beta}_1 x^* + t_{\frac{\alpha}{2}, n-2} \sqrt{\hat{\sigma}^2 \left(\frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{xx}} \right)} \right)$$

Observaciones:

- El ancho del intervalo de confianza para $\beta_0 + \beta_1 x^*$ depende de x^* . El ancho del intervalo es mínimo cuando $x^* = \bar{x}$ y crece a medida que $|x^* - \bar{x}|$ aumenta
- Al repetir los cálculos anteriores para varios valores diferentes de x^* pueden obtenerse intervalos de confianza para cada valor correspondiente de $\beta_0 + \beta_1 x^*$

Inferencias sobre los parámetros de Regresión

Intervalo de Predicción para futuras observaciones de Y^*

Un valor futuro de Y no es un parámetro sino una variable aleatoria; por eso se hace referencia a un intervalo de valores factibles para un valor Y futuro como **Intervalo de Predicción** en lugar de intervalo de confianza.

El error de predicción es $Y - (\hat{\beta}_0 + \hat{\beta}_1 x^*)$ una diferencia entre dos variables aleatorias. Existe por lo tanto más incertidumbre en la predicción que, en la estimación, así que un intervalo de predicción será más ancho que un intervalo de confianza.

$$E(Y^* - \hat{Y}^*) = 0 \quad V(Y^* - \hat{Y}^*) = \sigma^2 \left(1 + \frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{xx}} \right) \quad S_{Y^* - \hat{Y}^*} = \sqrt{\hat{\sigma}^2 \left(1 + \frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{xx}} \right)}$$

Por lo tanto, $Y^* - \hat{Y}^*$ tiene distribución normal con esperanza y varianza anteriores

Inferencias sobre los parámetros de Regresión

Intervalo de Predicción para futuras observaciones de Y^*

Teorema: La variable

$$T = \frac{Y^* - \hat{Y}^*}{\sqrt{\hat{\sigma}^2 \left(1 + \frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{xx}} \right)}}$$

tiene distribución student con $n - 2$ grados de libertad

Por el argumento usual llegamos al siguiente intervalo de predicción de nivel $(1 - \alpha)$ para Y^*

$$\left(\hat{Y}^* - t_{\frac{\alpha}{2}, n-2} \sqrt{\hat{\sigma}^2 \left(1 + \frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{xx}} \right)}; \hat{Y}^* + t_{\frac{\alpha}{2}, n-2} \sqrt{\hat{\sigma}^2 \left(1 + \frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{xx}} \right)} \right)$$

Inferencias sobre los parámetros de Regresión

Repaso

Cálculo del Valor Crítico $t_{\frac{\alpha}{2}, n-2}$ o $t_{\alpha, n-2}$ en Probability Distributions :

$$X \sim t(v)$$

$$v = n - 2$$

$$X = t_{\frac{\alpha}{2}, n-2} \text{ o } t_{\alpha, n-2}$$

$$P(X > x) = \alpha/2 \text{ o } \alpha$$



Inferencias sobre los parámetros de Regresión

Repaso

Un P-valor muy chico significa mucha evidencia en contra de H_0 ; un P-valor alto significa que no hay evidencia en contra H_0 .

Regla de decisión:

Si $P - \text{valor} > 0.05$ entonces no se rechaza H_0 con nivel de significancia 0.05

Si $P - \text{valor} \leq 0.05$ entonces se rechaza H_0 con nivel de significancia 0.05

Inferencias sobre los parámetros de Regresión

Repaso

Cálculo de P-valor para t

Si las hipótesis son $H_0: \beta_1 = \beta_{10}$ vs $H_1: \beta_1 \neq \beta_{10}$:

P – valor = $P(|T| > |t_0|)$

Si las hipótesis son $H_0: \beta_1 = \beta_{10}$ vs $H_1: \beta_1 > \beta_{10}$:

P – valor = $P(T > t_0)$

Si las hipótesis son $H_0: \beta_1 = \beta_{10}$ vs $H_1: \beta_1 < \beta_{10}$:

P – valor = $P(T < t_0)$

De la misma forma para β_0

Inferencias sobre los parámetros de Regresión

Repaso

Calculo P – valor = $P(|T| > |t_0|)$ en Probability Distributions:

$$X \sim t(v)$$

$$v = n - 2$$

$$x = |t_0|$$

$$2P(X > |x|) = \text{P – valor}$$



Inferencias sobre los parámetros de Regresión

Repaso

Calculo P – valor = $P(T > t_0)$ en Probability Distributions:

$$X \sim t(v)$$

$$v = n - 2$$

$$x = t_0$$

$$P(X > x) = \text{P – valor}$$



Inferencias sobre los parámetros de Regresión

Repaso

Calculo P – valor = $P(T < t_0)$ en Probability Distributions:

$$X \sim t(v)$$

$$v = n - 2$$

$$x = t_0$$

$$P(X < x) = \text{P – valor}$$



Inferencias sobre los parámetros de Regresión

Ejemplo 2

La autoridad aeronáutica argentina realizó un estudio de operaciones de aerolíneas, en 18 compañías, que reveló que la relación entre el número de pilotos empleados y el número de aviones en servicio tenía una pendiente de 4,3. Estudios anteriores indicaban que la pendiente de esta relación era 4. Si se calculó que la desviación estándar de la de pendiente de regresión es 0,17, ¿hay razones para creer, que la pendiente verdadera ha cambiado?

Inferencias sobre los parámetros de Regresión

Resolución

$$n = 18 \quad \hat{\beta}_1 = 4,3 \quad \beta_{10} = 4 \quad S_{\hat{\beta}_1} = \sqrt{\frac{\hat{\sigma}^2}{S_{xx}}} = 0,17$$

Test para β_1

$$H_0: \beta_1 = 4 \quad \text{vs} \quad H_1: \beta_1 \neq 4$$

Inferencias sobre los parámetros de Regresión

Estadístico de prueba:

$$T = \frac{\hat{\beta}_1 - \beta_{10}}{\sqrt{\frac{\hat{\sigma}^2}{S_{xx}}}} \sim t_{n-2} \text{ bajo } H_0$$

$$t_0 = \frac{4,3 - 4}{0,17} = 1,7647$$

Cálculo del P-valor (con la App):

$$P - \text{valor} = P(|T| > |t_0|) = P(|T| > 1,7647) = 0,097$$

Conclusión: Como el $P - \text{valor} = 0,097 > 0,05$, No rechazo H_0 , entonces es factible creer que la pendiente no ha cambiado.

Inferencias sobre los parámetros de Regresión

Ejemplo 3

Considere los siguientes datos sobre el número de millas para ciertos automóviles, en millas por galón (mpg) y su peso en libras (wt)

Modelo	GMC	Geo	Honda	Hyundai	Infiniti	Isuzu	Jeep	Land	Lexus	Linclon
Wt (x)	4520	2065	2440	2290	3195	3480	4090	4535	3390	3930
Mpg (y)	15	29	31	28	23	21	15	13	22	18

a) Suponga que los ingenieros de Honda afirman que, en **promedio**, el Honda (o cualquier otro modelo de vehículo que pese 2440 libras) recorre más de 30 mpg. Con base en los resultados del análisis de regresión, ¿es esta afirmación creíble?, ¿por qué? Utilice un $(1 - \alpha) = 0,95$.

b) Los ingenieros de diseño para el Lexus tienen por **objetivo** lograr 18 mpg como ideal para dicho modelo (o cualquier otro que pese 3390 libras) con una confianza de 95%, aunque se espera que haya cierta variación. ¿Es probable que sea realista ese objetivo?

Inferencias sobre los parámetros de Regresión

Resolución

$$S_{xx} = 7283652,5 \quad S_{yy} = 360,5 \quad S_{xy} = -49967,5 \quad \bar{x} = 3393,5 \quad \bar{y} = 21,5 \quad n = 10$$

$$\hat{\beta}_1 = -0,0069 \quad \hat{\beta}_0 = 44,7802 \quad \hat{\sigma}^2 = 2,214$$

$$\hat{y} = -0,0069x + 44,7802$$

Inferencias sobre los parámetros de Regresión

Resolución

a) Intervalo de confianza para la respuesta media

$$\left(\hat{\beta}_0 + \hat{\beta}_1 x^* - t_{\frac{\alpha}{2}, n-2} \sqrt{\hat{\sigma}^2 \left(\frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{xx}} \right)}; \hat{\beta}_0 + \hat{\beta}_1 x^* + t_{\frac{\alpha}{2}, n-2} \sqrt{\hat{\sigma}^2 \left(\frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{xx}} \right)} \right)$$

Donde $x^* = 2440$

El nivel de confianza es $(1 - \alpha) = 0,95 \rightarrow \alpha = 0,05$ entonces $t_{\frac{\alpha}{2}, n-2} = t_{0,025,8} = 2,306$

Inferencias sobre los parámetros de Regresión

Reemplazando los valores en el intervalo:

$$\left(44,7802 - 0,0069(2440) \pm 2,306 \sqrt{2,214 \left(\frac{1}{10} + \frac{(2440 - 3393,5)^2}{7283652,5} \right)} \right)$$

ICM(Y) = (26,3173 ; 29,5711) es el Intervalo de confianza de 0,95 para la media de mpg cuando el peso es de 2440 libras.

Respuesta: La afirmación hecha por los ingenieros no es creíble, ya que el intervalo de confianza de respuesta media indica un rango menor que 30 mpg.

Inferencias sobre los parámetros de Regresión

b) Intervalo de confianza de predicción para futuras observaciones

$$\left(\hat{Y}^* - t_{\frac{\alpha}{2}, n-2} \sqrt{\hat{\sigma}^2 \left(1 + \frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{xx}} \right)}; \hat{Y}^* + t_{\frac{\alpha}{2}, n-2} \sqrt{\hat{\sigma}^2 \left(1 + \frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{xx}} \right)} \right)$$

Donde $\hat{Y}^* = \hat{\beta}_0 + \hat{\beta}_1 x^*$, $x^* = 3390$ entonces $\hat{Y}^* = -0,0069 \cdot (3390) + 44,7802 = 21,3892$

El nivel de confianza es $(1 - \alpha) = 0,95 \rightarrow \alpha = 0.05$ entonces $t_{\frac{\alpha}{2}, n-2} = t_{0,025,8} = 2,306$

Inferencias sobre los parámetros de Regresión


Reemplazando los valores en el intervalo:

$$\left(21,3892 \pm 2,306 \sqrt{2,214 \left(1 + \frac{1}{10} + \frac{(2440 - 3393,5)^2}{7283652,5} \right)} \right)$$

IP(Y) = (17,5918 ; 25,1866) es el intervalo de confianza de 0.95 para predecir los mpg a partir de los pesos en libras.

Respuesta: El objetivo de lograr 18 mpg como ideal para el modelo Lexus es probable que sea realista, ya dicho mpg se encuentra en el intervalo de predicción.

Regresión Lineal Múltiple



Modelo de Regresión Lineal Múltiple

$$y_i = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_k x_k + \varepsilon_i$$


Los errores cumplen los mismos supuestos de un modelo de regresión lineal simple

Planteamiento general del modelo de regresión lineal múltiple

Para el modelo anterior se requiere conocer el valor de los $k + 1$ parámetros, para la cual se proporcionan n valores de la variable independiente y se obtiene las ecuaciones:

$$\begin{cases} y_1 = \beta_0 + \beta_1 x_{11} + \beta_2 x_{12} + \cdots + \beta_k x_{1k} \\ y_2 = \beta_0 + \beta_1 x_{21} + \beta_2 x_{22} + \cdots + \beta_k x_{2k} \\ \vdots \\ y_n = \beta_0 + \beta_1 x_{n1} + \beta_2 x_{n2} + \cdots + \beta_k x_{nk} \end{cases}$$

Regresión Lineal Múltiple



Notación matricial del sistema


$$\mathbf{Y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} \quad \mathbf{X} = \begin{pmatrix} 1 & x_{11} & x_{12} & \dots & x_{1k} \\ 1 & x_{21} & x_{22} & \dots & x_{2k} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \dots & x_{nk} \end{pmatrix} \quad \boldsymbol{\beta} = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_k \end{pmatrix}$$

Entonces nos queda el siguiente sistema matricial:

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} \quad (1)$$

Dado que la columna de la matriz $\mathbf{Y}$ no es una combinación lineal de las columnas de la matriz $\mathbf{X}$ el sistema no puede ser resuelto (Sistema Incompatible) , por ende buscaremos una **solución aproximada** de **mínimos cuadrados** usando las ecuaciones normales asociada al sistema (1).

Regresión Lineal Múltiple



El sistema de ecuaciones normales asociado al sistema (1) está dado por:

$$\mathbf{X}^T \mathbf{Y} = \mathbf{X}^T \mathbf{X} \boldsymbol{\beta} \quad (2)$$

Este sistema (2), a diferencia del sistema (1), es un sistema cuadrado (misma cantidad de incógnitas y ecuaciones) que bajo condiciones usuales define $\boldsymbol{\beta}$ de manera única.

Usando el álgebra y despejando $\boldsymbol{\beta}$, la solución por mínimos cuadrados del sistema (1) está dada por:


$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y}$$

Donde:

$$\hat{\boldsymbol{\beta}} = (\hat{\beta}_1, \hat{\beta}_2, \dots, \hat{\beta}_k)$$

Y a $(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T$ se lo llama **Pseudoinversa** de la matriz $\mathbf{X}$

Regresión Lineal Múltiple



Partiendo del modelo de Regresión Lineal Múltiple


$$y_i = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_k x_k + \varepsilon_i$$

Las Suposiciones son las mismas que el modelo de regresión lineal simple y la estimación de los parámetros se obtendrán de la misma forma, por el método de mínimos cuadrados.

Función a minimizar:

$$f(\beta_0, \beta_1, \dots, \beta_k) = \sum_{i=1}^n [y_i - (\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_k x_k)]^2$$
$$f(\beta_0, \beta_1, \dots, \beta_k) = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_1 - \beta_2 x_2 - \cdots - \beta_k x_k)^2$$

Regresión Lineal Múltiple



Haciendo las respectivas derivadas igualadas a cero y despejando, se obtiene las **ecuaciones normales**:

$$n\beta_0 + \beta_1 \sum x_{1i} + \beta_2 \sum x_{2i} + \cdots + \beta_k \sum x_{ki} = \sum y_i$$

$$\beta_0 \sum x_{1i} + \beta_1 \sum x_{1i}^2 + \beta_2 \sum x_{1i}x_{2i} + \cdots + \beta_k \sum x_{1i}x_{ki} = \sum x_{1i}y_i$$


$$\beta_0 \sum x_{2i} + \beta_1 \sum x_{1i}x_{2i} + \beta_2 \sum x_{2i}^2 + \cdots + \beta_k \sum x_{2i}x_{ki} = \sum x_{2i}y_i$$

⋮

⋮

$$\beta_0 \sum x_{ki} + \beta_1 \sum x_{ki}x_{1i} + \beta_2 \sum x_{ki}x_{2i} + \cdots + \beta_k \sum x_{ki}^2 = \sum x_{ki}y_i$$


Regresión Lineal Múltiple



El sistema de ecuaciones obtenidas se dispone en forma matricial de la siguiente manera:

$$\underbrace{\begin{pmatrix} n & \sum x_{1i} & \sum x_{2i} & \cdots & \sum x_{ki} \\ \sum x_{1i} & \sum x_{1i}^2 & \sum x_{1i}x_{2i} & \cdots & \sum x_{1i}x_{ki} \\ \sum x_{2i} & \sum x_{1i}x_{2i} & \sum x_{2i}^2 & \cdots & \sum x_{2i}x_{ki} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \sum x_{ki} & \sum x_{ki}x_{1i} & \sum x_{ki}x_{2i} & \cdots & \sum x_{ki}^2 \end{pmatrix}}_M \underbrace{\begin{pmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \vdots \\ \vdots \\ \vdots \\ \beta_k \end{pmatrix}}_{\beta} = \underbrace{\begin{pmatrix} \sum y_i \\ \sum x_{1i}y_i \\ \sum x_{2i}y_i \\ \vdots \\ \sum x_{ki}y_i \end{pmatrix}}_Y$$

Regresión Lineal Múltiple



Entonces queda el siguiente sistema matricial (con la misma cantidad de incógnitas y ecuaciones) a resolver es:

$$\mathbf{Y} = \mathbf{M}\boldsymbol{\beta}$$

Cuya solución esta dada por:

$$\hat{\boldsymbol{\beta}} = \mathbf{M}^{-1}\mathbf{Y}$$


Donde:

$$\hat{\boldsymbol{\beta}} = (\hat{\beta}_1, \hat{\beta}_2, \dots, \hat{\beta}_k)$$

Entonces:

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1x_1 + \hat{\beta}_2x_2 + \dots + \hat{\beta}_kx_k$$

Regresión Lineal Múltiple




Calculo de los coeficientes usando determinantes

Denotamos **D** (con $D \neq 0$) al determinante de la matriz M:

$$\begin{pmatrix} n & \sum x_{1i} & \sum x_{2i} & \cdots & \sum x_{ki} \\ \sum x_{1i} & \sum x_{1i}^2 & \sum x_{1i}x_{2i} & \cdots & \sum x_{1i}x_{ki} \\ \sum x_{2i} & \sum x_{1i}x_{2i} & \sum x_{2i}^2 & \cdots & \sum x_{2i}x_{ki} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \sum x_{ki} & \sum x_{ki}x_{1i} & \sum x_{ki}x_{2i} & \cdots & \sum x_{ki}^2 \end{pmatrix}$$

Regresión Lineal Múltiple




Denotamos $\mathbf{D}_0$ al determinante de la matriz:

$$\begin{pmatrix} \sum y_i & \sum x_{1i} & \sum x_{2i} & \cdots & \sum x_{ki} \\ \sum x_{1i}y_i & \sum x_{1i}^2 & \sum x_{1i}x_{2i} & \cdots & \sum x_{1i}x_{ki} \\ \sum x_{2i}y_i & \sum x_{1i}x_{2i} & \sum x_{2i}^2 & \cdots & \sum x_{2i}x_{ki} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \sum x_{ki}y_i & \sum x_{ki}x_{1i} & \sum x_{ki}x_{2i} & \cdots & \sum x_{ki}^2 \end{pmatrix}$$

Lo que hicimos fue reemplazar la primera columna de la matriz $\mathbf{M}$ por $\mathbf{Y}$

Regresión Lineal Múltiple




Denotamos $\mathbf{D}_1$ al determinante de la matriz:

$$\begin{pmatrix} n & \sum y_i & \sum x_{2i} & \cdots & \sum x_{ki} \\ \sum x_{1i} & \sum x_{1i}y_i & \sum x_{1i}x_{2i} & \cdots & \sum x_{1i}x_{ki} \\ \sum x_{2i} & \sum x_{2i}y_i & \sum x_{2i}^2 & \cdots & \sum x_{2i}x_{ki} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \sum x_{ki} & \sum x_{ki}y_i & \sum x_{ki}x_{2i} & \cdots & \sum x_{ki}^2 \end{pmatrix}$$

Lo que hicimos fue reemplazar la segunda columna de la matriz $\mathbf{M}$ por $\mathbf{Y}$

Regresión Lineal Múltiple




Denotamos $\mathbf{D}_k$ al determinante de la matriz :

$$\begin{pmatrix} n & \sum x_{1i} & \sum x_{2i} & \cdots & \sum y_i \\ \sum x_{1i} & \sum x_{1i}^2 & \sum x_{1i}x_{2i} & \cdots & \sum x_{1i}y_i \\ \sum x_{2i} & \sum x_{1i}x_{2i} & \sum x_{2i}^2 & \cdots & \sum x_{2i}y_i \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \sum x_{ki} & \sum x_{ki}x_{1i} & \sum x_{ki}x_{2i} & \cdots & \sum x_{ki}y_i \end{pmatrix}$$

Lo que hicimos fue reemplazar la última columna de la matriz M por Y

Regresión Lineal Múltiple




Los estimadores de los coeficientes se calcularán como:

$$\hat{\beta}_0 = \frac{D_0}{D} \quad \hat{\beta}_1 = \frac{D_1}{D} \quad \hat{\beta}_2 = \frac{D_2}{D} \quad \dots \dots \quad \hat{\beta}_k = \frac{D_k}{D}$$

Entonces:

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \dots + \hat{\beta}_k x_k$$

Regresión Lineal Múltiple



Estimación de la varianza

$$\hat{\sigma}^2 = \frac{SS_R}{n - k - 1} = \frac{\sum (y_i - \hat{y}_i)^2}{n - k - 1}$$

Coefficiente de determinación ajustado:


$$R_a^2 = 1 - (1 - R^2) \left(\frac{n - 1}{n - k - 1} \right) \rightarrow 0 \leq R_a^2 \leq 1$$

Coefficiente de correlación:

$$r_a = \sqrt{R_a^2} \rightarrow -1 \leq r_a \leq 1$$

Siendo k el número de variables independientes

Regresión Lineal Múltiple




Ejemplo 4 Se realizó un experimento para determinar si era posible predecir el peso de un animal después de un periodo determinado con base en su peso inicial y la cantidad de alimento que consumía. Se registran los siguientes datos en kilogramos:

N° de animal	Peso final del animal (Y)	Peso inicial del animal (X1)	Peso del Alimento (X2)
1	95	40	280
2	75	35	225
3	80	30	260
4	100	45	290
5	95	40	310
6	70	35	185
7	50	30	175
8	80	45	230
9	90	45	235
10	85	35	230

- Estime la ecuación de regresión correspondiente para el problema.
- Prediga cuanto pesara un animal que comienza pesando 35 kg después de consumir 250 kg de alimentos.
- Calcule los indicadores para la misma.

Regresión Lineal Múltiple




Resolución

a) Como son dos las variables independientes X_1 y X_2 las ecuaciones son:

$$\left\{ \begin{array}{l} n\beta_0 + \beta_1 \sum x_{1i} + \beta_2 \sum x_{2i} = \sum y_i \\ \beta_0 \sum x_{1i} + \beta_1 \sum x_{1i}^2 + \beta_2 \sum x_{1i}x_{2i} = \sum x_{1i}y_i \\ \beta_0 \sum x_{2i} + \beta_1 \sum x_{1i}x_{2i} + \beta_2 \sum x_{2i}^2 = \sum x_{2i}y_i \end{array} \right.$$


Regresión Lineal Múltiple



Calculamos las sumatorias correspondientes a partir de los datos:

Nº de animal	Peso final del animal (Y)	Peso inicial del animal (X_1)	Peso del Alimento (X_2)	(X_1^2)	(X_2^2)	$X_1 \cdot X_2$	$X_1 \cdot Y$	$X_2 \cdot Y$
1	95	40	280	1600	78400	11200	3800	26600
2	75	35	225	1225	50625	7875	2625	16875
3	80	30	260	900	67600	7800	2400	20800
4	100	45	290	2025	84100	13050	4500	29000
5	95	40	310	1600	96100	12400	3800	29450
6	70	35	185	1225	34225	6475	2450	12950
7	50	30	175	900	30625	5250	1500	8750
8	80	45	230	2025	52900	10350	3600	18400
9	90	45	235	2025	55225	10575	4050	21150
10	85	35	230	1225	52900	8050	2975	19550
Sumatoria	820	380	2420	14750	602700	93025	31700	203525

Regresión Lineal Múltiple




Reemplazando los valores en nuestra ecuación:

$$\begin{cases} 10\beta_0 + 380\beta_1 + 2420\beta_2 = 820 \\ 380\beta_0 + 14750\beta_1 + 93025\beta_2 = 31700 \\ 2420\beta_0 + 93025\beta_1 + 602700\beta_2 = 203525 \end{cases}$$

En forma matricial:

$$\begin{pmatrix} 10 & 380 & 2420 \\ 380 & 14750 & 93025 \\ 2420 & 93025 & 602700 \end{pmatrix} \begin{pmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{pmatrix} = \begin{pmatrix} 820 \\ 31700 \\ 203525 \end{pmatrix}$$

Regresión Lineal Múltiple




Donde:

$$\mathbf{M} = \begin{pmatrix} 10 & 380 & 2420 \\ 380 & 14750 & 93025 \\ 2420 & 93025 & 602700 \end{pmatrix} \quad \mathbf{Y} = \begin{pmatrix} 820 \\ 31700 \\ 203525 \end{pmatrix}$$

Entonces:

$$\hat{\boldsymbol{\beta}} = \begin{pmatrix} 10 & 380 & 2420 \\ 380 & 14750 & 93025 \\ 2420 & 93025 & 602700 \end{pmatrix}^{-1} \begin{pmatrix} 820 \\ 31700 \\ 203525 \end{pmatrix}$$

Regresión Lineal Múltiple




Resolviendo el producto matricial:

$$\begin{pmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \\ \hat{\beta}_2 \end{pmatrix} = \begin{pmatrix} -11,0546 \\ 0,9139 \\ 0,2410 \end{pmatrix}$$

Entonces la ecuación de regresión estimada será:

$$\hat{y} = -11,0546 + 0,9139x_1 + 0,2410x_2$$

Regresión Lineal Múltiple



b) Predicción del peso de un animal que comienza pesando 35 kg después de consumir 250 kg de alimentos:

$$\hat{y} = -11,0546 + 0,9139 \cdot (35) + 0,2410 \cdot (250) = 81,2 \text{ kg}$$

c) Calculo de los indicadores


Necesitamos:

$$SS_R = \sum (y_i - \hat{y}_i)^2 = 240,9284$$

$$R^2 = 1 - \frac{SS_R}{S_{yy}} = 0,8771$$

$$S_{yy} = \sum (y_i - \bar{y})^2 = 1960$$

Regresión Lineal Múltiple




Entonces:

$$\sigma_a^2 = \frac{SS_R}{n - k - 1} = \frac{240,9284}{10 - 2 - 1} = 34,4183$$

$$R_a^2 = 1 - (1 - R^2) \left(\frac{n - 1}{n - k - 1} \right) = 1 - (1 - 0,8771) \left(\frac{10 - 1}{10 - 2 - 1} \right) = 0,8420$$

$$r_a = \sqrt{R_a^2} = \sqrt{0,8420} = 0,91$$

Regresión Lineal Múltiple




Ejemplo 5

Un profesor de Estudios Sociales considera que la nota obtenida en su examen final (Y) depende linealmente del número de horas que duerme un alumno en la noche antes del examen (X_1) y del número de horas de estudio en la semana previa al examen (X_2). Seguidamente se presentan los datos obtenidos de 4 estudiantes:

X_1	4	1	6	8
X_2	4	8	12	15
Y	45	60	80	96

- a)** Estime los coeficientes β_0 , β_1 y β_2 en la ecuación de regresión múltiple $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2$.
- b)** De acuerdo a la ecuación estimada, ¿Qué tiene más peso en la nota: las horas de estudio o las horas que duerme la noche antes del examen?

Regresión Lineal Múltiple




Resolución

$$\mathbf{a)} \quad \mathbf{Y} = \begin{pmatrix} 45 \\ 60 \\ 80 \\ 96 \end{pmatrix} \quad \mathbf{X} = \begin{pmatrix} 1 & 4 & 4 \\ 1 & 1 & 8 \\ 1 & 6 & 12 \\ 1 & 8 & 15 \end{pmatrix} \quad \mathbf{X}^T = \begin{pmatrix} 1 & 1 & 1 & 1 \\ 4 & 1 & 6 & 8 \\ 4 & 8 & 12 & 15 \end{pmatrix}$$

$$\hat{\boldsymbol{\beta}} = \left[\begin{pmatrix} 1 & 1 & 1 & 1 \\ 4 & 1 & 6 & 8 \\ 4 & 8 & 12 & 15 \end{pmatrix} \begin{pmatrix} 1 & 4 & 4 \\ 1 & 1 & 8 \\ 1 & 6 & 12 \\ 1 & 8 & 15 \end{pmatrix} \right]^{-1} \begin{pmatrix} 1 & 1 & 1 & 1 \\ 4 & 1 & 6 & 8 \\ 4 & 8 & 12 & 15 \end{pmatrix} \begin{pmatrix} 45 \\ 60 \\ 80 \\ 96 \end{pmatrix}$$

$$\hat{\boldsymbol{\beta}} = \begin{pmatrix} 24,533 \\ 0,7702 \\ 4,3136 \end{pmatrix}$$

Regresión Lineal Múltiple



La ecuación de regresión estimada queda:

$$\hat{y} = 24,533 + 0,7702x_1 + 4,3136x_2$$

b) Las horas de estudio tiene mayor peso ya que tiene el coeficiente mas alto ($\hat{\beta}_2 > \hat{\beta}_1$)

The background of the slide features a dark blue-grey gradient with faint, light-grey line art of financial charts. On the left and right sides, there are candlestick charts with vertical bars representing price movements. In the center, there are several overlapping line graphs, including a dotted line and a solid line, suggesting trend analysis or moving averages. The overall aesthetic is professional and data-oriented.

Fin

¡Muchas Gracias !